

IIMAS
Universidad Nacional Autónoma de México


Agregando ruido a DG para llegar al mínimo global.

Aprendizaje máquina teórico.

Alejandro Antonio Estrada Franco

>Agregando ruido a DG para llegar al mínimo global

1



Para $f : \mathbb{R}^d \rightarrow \mathbb{R}$ el algoritmo que estudiaremos es el siguiente[1]:

Algoritmo 1 : Decenso de Gradiente Ruidoso; $x_1 \in \mathbb{R}^d; \alpha > 0; \sigma > 0$

- ▶ para $t = 1, 2, \dots$
- ▶ Generar una realización de la v.a. $U_t \sim \text{Unif}[B_{r=1}^2(0)]$
- ▶ Calcular $\nabla f(x_t)$
- ▶ $x_{t+1} = x_t - \alpha \nabla f(x_t) + \sigma U_t$

>Agregando ruido a DG para llegar al mínimo global


2

Definición 1: (componente σ -suave). Para todo $\sigma > 0$ y una función $f : \mathbb{R}^d \rightarrow \mathbb{R}$, la componente σ -suave de f se define como:

$$f_\sigma(x) = \mathbb{E}_U[f(x + \sigma U)] = \int_{B_{r=1}^2(0)} f(x + \sigma y) p_U(y) dy$$

definimos también:

$$r_\sigma(x) = f(x) - f_\sigma(x)$$



>Agregando ruido a DG para llegar al mínimo global

3

Algunas observaciones y notación:

- ▶ Supondremos f continuamente diferenciable para obtener
$$\nabla f_\sigma(x) = \nabla \mathbb{E}_U[f(x + \sigma U)] = \mathbb{E}_U[\nabla f(x + \sigma U)] = (\nabla f)_\sigma(x); \text{ es decir:}$$

$$\nabla f_\sigma(x) = (\nabla f)_\sigma(x).$$

- ▶ También denotaremos $\mathbb{E}_t[\cdot] = \mathbb{E}_{U_t}[\cdot]$, así mismo denominaremos $e_1 = x_1$, y $e_{t+1} = \mathbb{E}_t[x_{t+1}]$, además $\mathbb{E}[\cdot]$ denotará el valor esperado con respecto a la distribución conjunta de las uniformes (se toman independientes). Por ejemplo si x_t es el último punto del algoritmo, tenemos $\mathbb{E}[x_t] = \mathbb{E}_1 \dots \mathbb{E}_{t-1}[x_t]$.

>Agregando ruido a DG para llegar al mínimo global

4

- ▶ Asumiremos también que la componente σ -suave f_σ es l -fuertemente convexa, y L -suave con $0 < l \leq L < \infty$. En consecuencia f_σ tiene un único minimizador x_σ^* , con $f_\sigma^* = f_\sigma(x_\sigma^*)$.
- ▶ Otro supuesto que se considera es que existen escalares M y μ tales que los gradientes ∇f y ∇f_σ satisfacen:
$$\mathbb{V}_U[\nabla f(e + \sigma U)] \leq M_\sigma + \mu \|\nabla f_\sigma(e)\|^2$$
- ▶ Finalmente consideraremos que f es L_0 -Lipschitz con respecto a la norma euclíadiana en \mathbb{R}^d

>Agregando ruido a DG para llegar al mínimo global

5

Lema 1: Bajo las iteraciones de DGR se satisface para todo $n \in \mathbb{N}$:

$e_{t+1} = e_t - \alpha \nabla f(e_t + \sigma U_{t-1}) + \sigma U_{t-1}$ mas aún se cumple también $\mathbb{E}_{t-1}[e_{t+1}] = e_t - \alpha \nabla f_\sigma(e_t)$.

Demostración: Para cada $t \in \mathbb{N}$ tenemos $x_{t+1} = x_t - \alpha \nabla f(x_t) + \sigma U_t$, tomando esperanzas con respecto a U_t ; $e_{t+1} = x_{t+1} - \alpha \nabla f(x_t)$ de donde $e_{t+1} = x_{t+1} - \sigma U_t$ luego $e_{t+1} - e_t = -\alpha \nabla f(e_t + \sigma U_{t-1}) + \sigma U_{t-1}$ concluimos $\mathbb{E}_{t-1}[e_{t+1} - e_t] = -\alpha(\nabla f)_\sigma(e_t)$ \square .

Lema 2: Se cumple $f_\sigma(\mathbb{E}[x_{t+1}]) \leq \mathbb{E}[f_\sigma(e_{t+1})]$

Demostración: De la convexidad de f_σ y la desigualdad de Jensen:

$$\begin{aligned} f_\sigma(\mathbb{E}[x_{t+1}]) &= f_\sigma(\mathbb{E}_1 \dots \mathbb{E}_{t-1} \mathbb{E}_t[x_{t+1}]) \\ &= f_\sigma(\mathbb{E}_1 \dots \mathbb{E}_{t-1}[e_{t+1}]) \\ &= f_\sigma(\mathbb{E}[e_{t+1}]) \leq \mathbb{E}[f_\sigma(e_{t+1})] \end{aligned}$$

\square .

>Agregando ruido a DG para llegar al mínimo global

6

Lema 3: Para todo $t \in \mathbb{N}$ se verifica lo siguiente:

$$\mathbb{E}_{t-1} ||\mathbf{e}_{t-1} - \mathbf{e}_t|| \leq 2\alpha^2(\mu + 1) ||\nabla f_\sigma(\mathbf{e}_t)||^2 + \alpha^2 M$$

donde:

$$M = 2M_\sigma + 2 \left(\frac{\sigma}{\alpha} \right)^2$$

Teorema 1: Para todo $t \in \mathbb{N}$ se cumple:

$$f_\sigma(\mathbb{E}[x_{t+1}]) - f_\sigma^* - \frac{\alpha LM}{2I} \leq \rho^t \left(f_\sigma(x_1) - f_\sigma^* - \frac{\alpha LM}{2I} \right)$$

Si

$$0 < \alpha \leq \frac{1}{2L(\mu + 1)}$$

donde $\rho = 1 - \alpha I \in (\frac{1}{2}, 1)$

>Agregando ruido a DG para llegar al mínimo global

7

Lema 4: Para todo $\sigma > 0$ se cumple $|f_\sigma(x) - f(x)| \leq L_0\sigma$

Demostración:

$$\begin{aligned}|f_\sigma(x) - f(x)| &= |\mathbb{E}_U[f(x + \sigma U) - f(x)]| \\&\leq \mathbb{E}_U|f(x + \sigma U) - f(x)| \\&\leq L_0 \mathbb{E}_U[|\sigma U|] = L_0\sigma \mathbb{E}_U[|U|] \leq L_0\sigma \quad \square.\end{aligned}$$

Lema 5: $f_\sigma^* \leq f^* + L_0\sigma$

Demostración: Tenemos que $f(x) = f_\sigma(x) + r_\sigma(x)$, entonces:

$$f^* = \min_{x \in \mathbb{R}^d} f(x) \geq \min_{x \in \mathbb{R}^d} f_\sigma(x) + \min_{x \in \mathbb{R}^d} r_\sigma(x) = f_\sigma^* + \min_{x \in \mathbb{R}^d} r_\sigma(x)$$

De acuerdo al Lema 4:

$$-L_0\sigma \leq \min_{x \in \mathbb{R}^d} r_\sigma \leq L_0\sigma$$

Entonces tenemos $f^* \geq f_\sigma^* - L_0\sigma \quad \square.$

>Agregando ruido a DG para llegar al mínimo global

Teorema 2: Para α y ρ como en el Teorema 1 se cumple para todo $t \in \mathbb{N}$:

$$f(\mathbb{E}[x_{t+1}]) - f^* \leq \rho^t M_1 + M_2$$

Donde:

$$M_1 = f_\sigma(x_1) - f_\sigma^* - \frac{\alpha L (M_\sigma + (\frac{\sigma}{\alpha})^2)}{I},$$

$$M_2 = \alpha \left(\frac{LM_\sigma}{I} + \frac{L(\frac{\sigma}{\alpha})^2}{I} + L_0 \left(\frac{\sigma}{\alpha} \right) \right) + L_0 \sigma$$

Demostración: Por el Lema 4 tenemos para todo $t \in \mathbb{N}$;
 $f(\mathbb{E}[x_{t+1}]) \leq f_\sigma(\mathbb{E}[x_{t+1}]) + L_0 \sigma = f_\sigma(\mathbb{E}[x_{t+1}]) + \alpha L_0 \left(\frac{\sigma}{\alpha} \right)$, luego del Lema 5 $-f^* \leq -f_\sigma^* + L_0 \sigma$ por lo que tenemos:

$$f(\mathbb{E}[x_{t+1}]) - f^* \leq f_\sigma(\mathbb{E}[x_{t+1}]) - f_\sigma^* + \alpha L_0 \left(\frac{\sigma}{\alpha} \right) + L_0 \sigma$$

>Agregando ruido a DG para llegar al mínimo global

9


Del Teorema 1 tenemos:

$$\begin{aligned} f(\mathbb{E}[x_{t+1}]) - f^* &\leq f_\sigma(\mathbb{E}[x_{t+1}]) - f_\sigma^* + \alpha L_0 \left(\frac{\sigma}{\alpha} \right) + L_0 \sigma \\ &\leq \rho^t \left(f_\sigma(x_1) - f_\sigma^* - \frac{\alpha LM}{2I} \right) + \frac{\alpha LM}{2I} + \alpha L_0 \left(\frac{\sigma}{\alpha} \right) + L_0 \sigma \\ &= \rho^t M_1 + \alpha \left(\frac{2M_\sigma + 2 \left(\frac{\sigma}{\alpha} \right)^2}{2I} + L_0 \left(\frac{\sigma}{\alpha} \right) \right) + L_0 \sigma \\ &= \rho^t M_1 + M_2 \quad \square. \end{aligned}$$

>Agregando ruido a DG para llegar al mínimo global

10


Ejemplo: Consideremos la función
 $f(x, y) = x^2 + y^2 - \cos(5\pi x) - \cos(5\pi y)$



>Agregando ruido a DG para llegar al mínimo global

11


Se ilustran cuatro ejecuciones del algoritmo GDR con
 $t = 100$, $x_1 = (5, 0)$, $\sigma = 0,05$, $\alpha = 0,02$



>Agregando ruido a DG para llegar al mínimo global

12


Se ilustran cuatro ejecuciones del algoritmo GDR con $t = 100$, $x_1 = (5, 0)$, $\sigma = 0,01$, $\alpha = 0,015$



>Agregando ruido a DG para llegar al mínimo global

13

Se ilustran cuatro ejecuciones del algoritmo GDR con $t = 100$, $x_1 = (5, 0)$, $\sigma = 0,015$, $\alpha = 0,015$



>Agregando ruido a DG para llegar al mínimo global

- [1] Xuliang Quin, Xin Xiu y Xiaopeng Luo. «Global Convergence of Noisy Gradient Descent». En: *IEEE International Conference on Systems, Man, and Cybernetics (SMC)* (2022).